

刘钢

大模型推理优化 / 边缘 AI 算法工程师

+86 159-9519-7640 | insistgang@163.com | 上海 | GitHub | Blog

教育背景

上海工程技术大学 · 硕士 (电子信息 – 人工智能方向) 2024.09 – 2027.06

GPA: 3.36 / 4.0 导师: 刘翔 教授 荣誉: 硕士研究生学业一等奖学金、优秀共产党员 / 党员之星、三好学生 / 优秀共青团员 / 优秀团干部、团干部示范典型 / 活力团支部班长/团支书

宿迁学院 · 学士 (信息与计算科学) 2017.09 – 2021.06

GPA: 3.23 / 4.0 导师: 荣誉: 校级优秀毕业设计、中共党员 (2021)

专业技能

- 推理优化与端侧部署**: 主攻 LLM INT4 权重量化 (Qwen2-7B 显存 14GB 压缩至 5.8GB, 单卡 42 tokens/s)、QLoRA 微调、vLLM/TensorRT FP16/INT8 编译导出与 NVIDIA Jetson Orin Nano 边缘端部署调优。
- 大模型与多模态 (LLM/VLM/Agent)**: 精通 Qwen2 / Qwen2.5-VL 多模态微调、RAG 检索增强架构 (ChromaDB 8 万+条向量检索)、Prompt 工程及 4 层多智能体 (Multi-Agent) 协同架构设计。
- 计算机视觉与深度学习**: 熟练掌握 YOLO 系列 (P2 高分辨率特征金字塔、自适应特征融合 AMSFF、解耦检测头 DCH、YOLO-seg 实例分割)、ReID 消除重复计数、单目测距与 OpenCV 视觉处理。
- 工程开发与全栈工具链**: 精通 Python 与现代 C/C++; 熟练掌握 Linux/Shell 生产开发、FastAPI 高并发异步后端、React 前端开发、SQLite FTS5 全文检索及 Typst 自动化文档编译。

核心项目与科研经历

多智能体协同网络安全威胁智能分析系统 | 华为杯网安专项赛 · 国家三等奖 (队长) 2025.07 – 2025.10

大模型研发与全栈架构 技术栈: Qwen2-7B, INT4 量化, QLoRA, Multi-Agent, RAG, ChromaDB

- 主导开源大模型 Qwen2-7B 的 INT4 权重量化部署, 将运行显存由 14GB 压缩至 5.8GB (降低 58.5%), 实现消费级单卡 42 tokens/s 离线推理。
- 设计 4 层多智能体 (Multi-Agent) 协同研判架构, 基于 ChromaDB 毫秒级检索 8 万+ 威胁情报条目, 分析准确率提升 12%。

电路系统框图多模态智能识别与逻辑解析系统 | 集成电路 EDA 精英赛 · 国家三等奖 2025.09 – 2025.11

多模态大模型研发 技术栈: YOLOv8, Qwen2.5-VL, LoRA 微调, 拓扑理解, 图元识别

- 提出“YOLOv8 空间几何定位 + Qwen2.5-VL 拓扑语义理解”级联架构, 元件定位准确率达 95%+, 逻辑推断 F1 达 0.87。
- 微调专用 LoRA 适配器, 实现原理图从图像输入到标准网表 (Netlist) 逆向生成的全流程自动化。

智慧城市井盖状态细粒度检测与遥感违建边缘部署 | 硕士核心课题 / 中文核心在投 2024.10 – 至今

第一作者 / 核心算法设计 技术栈: YOLOv11, 特征金字塔 P2, AMSFF, Jetson Orin Nano, TensorRT

- 在 YOLOv11 骨干网络中引入 P2 层高分辨率特征金字塔与自适应多尺度特征融合 (AMSFF), 细粒度状态识别 mAP50 达到 93.2%。
- 完成 TensorRT FP16/INT8 量化与算子融合, 部署至 NVIDIA Jetson Orin Nano 边缘设备, 端侧推理吞吐量达 45+ FPS。

竞赛荣誉与学术成果

- 竞赛荣誉**: 全国大学生数学建模竞赛【国家二等奖】(队长); “华为杯”全国研究生网络安全专项赛【国家三等奖】(队长); 全国大学生集成电路 EDA 精英创新赛【国家三等奖】、华为杯 AI 创新大赛【国家三等奖】; 2026 第二十届研电赛【省级二等奖】(LinkAble)、2026 西门子杯智能制造挑战赛【省级二等奖】; 2025 西门子杯【省级一等奖】、第十九届研电赛【省级三等奖】、上海市智慧城市大赛【省级三等奖】。
- 学术成果**: 《基于 YOLOv11 深度学习的智慧城市井盖细粒度状态检测系统》(中文核心在投, 第一作者); 软著《研发费用智能核算与报表自动化 RPA 软件 V1.0》(独立研发)。